

COMP0171 Bayesian Deep Learning

2023 Past Paper — Model Answers

目录

1	Question 1: True/False [16 marks total]	2
1.1	1(a) [2 marks]	2
1.2	1(b) [2 marks]	2
1.3	1(c) [2 marks]	3
1.4	1(d) [2 marks]	3
1.5	1(e) [2 marks]	4
1.6	1(f) [2 marks]	4
1.7	1(g) [2 marks]	5
1.8	1(h) [2 marks]	5
2	Question 2: Lightning Round — Short Answer [14 marks total]	7
2.1	2(a) [6 marks]	7
2.2	2(b) [4 marks]	7
2.3	2(c) [4 marks]	8
3	Question 3: Deep Learning Architectures [15 marks total]	9
3.1	3(a) [2 marks]	9
3.2	3(b) [6 marks]	9
3.3	3(c)(i) [4 marks]	10
3.4	3(c)(ii) [3 marks]	10
3.5	3(c)(iii) [2 marks]	10
4	Question 4: Generative Models and Missing Data [35 marks total]	12
4.1	4(a)(i) [3 marks]	12
4.2	4(a)(ii) [5 marks]	12
4.3	4(a)(iii) [2 marks]	13
4.4	4(b)(i) [3 marks]	13
4.5	4(b)(ii) [5 marks]	14
4.6	4(b)(iii) [2 marks]	14
4.7	4(c)(i) [7 marks]	15
4.8	4(c)(ii) [3 marks]	15

4.9	4(c)(iii) [5 marks]	16
5	Question 5: Linearizing Predictions [20 marks total]	18
5.1	5(a) [5 marks]	18
5.2	5(b)(i) [5 marks]	18
5.3	5(b)(ii) [3 marks]	19
5.4	5(b)(iii) [2 marks]	20
5.5	5(c)(i) [2 marks]	20
5.6	5(c)(ii) [3 marks]	21

Shuhan Wang

1 Question 1: True/False [16 marks total]

1.1 1(a) [2 marks]

(T/F) Variational Bayes with a Gaussian posterior, is preferred over a Laplace approximation, because the variational Bayes method is able to capture multiple modes of posterior.

Answer

False.

Variational Bayes (VB) 使用 Gaussian 作为 approximate posterior $q(\theta) = \mathcal{N}(\theta|\mu, \Sigma)$ 时, 这个 Gaussian 本身是 **unimodal** 的, 因此不能捕捉 posterior 的多模态结构。

更进一步, VB 最小化的是 $D_{\text{KL}}(q||p)$ (forward KL), 这是一种 mode-seeking 行为: q 会坍缩到 posterior 的某一个 mode 上, 而不是覆盖所有 mode。所以 Gaussian VB 和 Laplace approximation 一样都是 unimodal approximation, 不能以此作为 VB 优于 Laplace 的理由。

VB 真正优于 Laplace 的地方在于: VB 通过优化 ELBO 来直接调整 q 的参数 (包括 mean 和 covariance), 而 Laplace 是在 MAP 点处做二阶 Taylor 展开来近似 covariance, 因此 VB 的 covariance 估计可能更准确。

1.2 1(b) [2 marks]

(T/F) Suppose you are training a machine learning model to identify the specific breed of a dog from a photo. The model mostly works well, but has low-confidence predictions on very rare breeds which only are present in a few training images. This low confidence is an example of epistemic uncertainty, which could be captured and quantified by using a Bayesian neural network.

Answer

True.

稀有品种在训练集中只有极少的样本, 模型对这些类别的参数 (权重) 了解不足, 导致 posterior $p(\theta|\mathcal{D})$ 在相关参数空间上分布很宽。这正是 **epistemic uncertainty** (认知不确定性) 的定义: 源于对模型参数的不确定性, 可以通过收集更多相关数据来减少。

BNN 通过维护权重的 posterior distribution $p(\theta|\mathcal{D})$ 而非点估计, 可以自然地量化这种不确定性。在 posterior predictive 中:

$$p(y|x, \mathcal{D}) = \int p(y|x, \theta) p(\theta|\mathcal{D}) d\theta$$

不同的 posterior sample θ 会对稀有品种给出不同的预测, 从而产生高 predictive variance, 正确反映出模型的不确定性。

1.3 1(c) [2 marks]

(T/F) Bayesian deep learning is particularly advantageous over non-Bayesian (“regular”) deep learning when datasets are very very large, leading to more accurate predictions.

Answer

False.

BDL 的核心优势在于小数据场景，而非大数据场景。当数据量极大时：

1. Posterior $p(\theta|\mathcal{D})$ 会变得非常集中 (sharply peaked)，趋近于以 MAP/MLE 解为中心的 delta function。此时 Bayesian 方法和点估计方法给出的预测差异很小。
2. BDL 的计算开销（维护和采样 posterior distribution）远大于标准 deep learning，而带来的额外收益（更好的 uncertainty quantification、更强的正则化）在大数据下边际递减。

BDL 真正有优势的场景是：数据量有限、需要可靠的 uncertainty quantification、需要利用 prior knowledge、以及需要做 model comparison 等。

1.4 1(d) [2 marks]

(T/F) You run into a long-lost friend who now has two children. You ask if at least one of the children is a boy, and the answer is yes. She shows you pictures of the children one at a time, first showing you a picture of a son. With only this information, and before being told anything about the other child, the probability that this child is also a boy is 50%.

Answer

True.

这是一个经典的 conditional probability 问题。关键在于区分两种不同的条件信息：

- 经典版本：“至少有一个男孩” $\Rightarrow P(\text{both boys} | \text{at least one boy}) = 1/3$
- 本题版本：她先展示了一个特定的孩子是男孩。

一旦一个特定的孩子已经被展示并确认为男孩，另一个孩子的性别与该事件独立。该独立性来自于我们假设每个孩子的性别是独立同分布的 ($P(\text{boy}) = P(\text{girl}) = 1/2$)。

因此 $P(\text{other child is boy} | \text{first shown child is boy}) = 1/2$ 。

直觉上：sequential reveal 改变了条件信息的结构。“至少有一个男孩”对称地约束了两个孩子的联合分布，但“先展示的这个是男孩”只约束了被展示的那个孩子，对另一个没有提供任何信息。

1.5 1(e) [2 marks]

(T/F) Suppose you fit a Bayesian neural network for a regression problem, with a Gaussian likelihood (i.e. a squared error loss). If we make a Gaussian approximation to the posterior over model weights, then the posterior predictive distribution for new datapoints is a mixture of Gaussians.

Answer

True.

设 $q(\theta|\mathcal{D}) = \mathcal{N}(\theta|\mu, \Sigma)$, likelihood 为 $p(y|x, \theta) = \mathcal{N}(y|f_\theta(x), \beta^{-1})$ 。Posterior predictive 为:

$$p(y|x, \mathcal{D}) = \int p(y|x, \theta) q(\theta|\mathcal{D}) d\theta = \int \mathcal{N}(y|f_\theta(x), \beta^{-1}) q(\theta|\mathcal{D}) d\theta$$

这是一个连续的 Gaussian mixture (无穷多个 Gaussian 分量, 每个对应一个 θ 值, 由 $q(\theta|\mathcal{D})$ 加权)。由于 $f_\theta(x)$ 是 deep network (非线性函数), 不同的 θ 给出不同的 mean $f_\theta(x)$, 所以整个积分是一个 (infinite) mixture of Gaussians。

注意: 这个 mixture 本身不一定是 Gaussian 的。只有在 linearized approximation 下, 该积分才能化简为单个 Gaussian。

1.6 1(f) [2 marks]

(T/F) You train a deep learning model for binary classification, and on a set of 100 challenging test inputs, there was high uncertainty in predictions (predicting one class or another with around 60% probability). However, on further examination, it turns out that it got over 90% of the class labels correct! This high accuracy shows that the model has fit the data well.

Answer

False.

这种情况说明模型没有很好地 **calibrate** (校准)。一个 well-calibrated 的模型应该满足: 当模型预测某个类的概率为 60% 时, 在所有这类预测中, 大约 60% 的样本应该确实属于该类。

然而这里模型预测概率约为 60%, 但实际正确率为 90%, 这说明模型是 **underconfident** (过于保守)。模型实际上比它自己“认为的”要准确得多。

高 accuracy 只说明 $\arg \max$ 预测正确率高, 但并不意味着模型 fit the data well。Good fit 应该同时包括 accuracy 和 calibration。一个 well-fit 的模型在此场景下应该以约 90% 的概率预测正确类别, 而非 60%。

1.7 1(g) [2 marks]

(T/F) You are interested in training a spam filter, to identify and filter undesirable emails. You have a dataset of emails, but require a human labeller to come in and manually tell you what emails are spam and which are not. This is a setting where active learning might be appropriate.

Answer

True.

Active learning 适用于以下特征的场景：

1. 有大量未标注数据（大量邮件）
2. 标注成本高（需要人类标注者逐一标注）
3. 模型可以选择性地请求最有信息量的样本进行标注

该场景完全满足这些条件。Active learning（例如通过 BALD 等 acquisition function）可以选择模型最不确定的邮件优先请求标注，从而用更少的标注量达到更高的模型性能。

注意：Active learning 不限于连续输入空间，邮件是离散/文本数据，同样适用。

1.8 1(h) [2 marks]

(T/F) Reparameterized gradient estimators for $\nabla_{\theta} \mathbb{E}_{p(x|\theta)}[f(\theta)]$ can be applied so long as two conditions hold:

- f is differentiable with respect to θ ;
- There exists a function g and a distribution $p(\epsilon)$ such that sampling $\epsilon \sim p(\epsilon)$ and computing $x = g(\theta, \epsilon)$ yields a sample x from $p(x|\theta)$.

Answer

False.

题目中给出的两个条件**不完整**。Reparameterization trick 的核心等式是：

$$\nabla_{\theta} \mathbb{E}_{p(x|\theta)}[f(x)] = \mathbb{E}_{p(\epsilon)}[\nabla_{\theta} f(g(\theta, \epsilon))]$$

为了让链式法则可以应用，我们需要 f 对 x 可微（而非对 θ ）。更准确地说，需要 $f(g(\theta, \epsilon))$ 对 θ 可微，这要求：

1. f 对 x 可微（ $x = g(\theta, \epsilon)$ 是中间变量）
2. $g(\theta, \epsilon)$ 对 θ 可微（reparameterization function 本身对参数可微）
3. 存在 reparameterization $x = g(\theta, \epsilon)$, $\epsilon \sim p(\epsilon)$ 使得 $x \sim p(x|\theta)$

题目中第一个条件说的是“ f is differentiable with respect to θ ”，但实际上关键的要求是 f 对 x 可微。

Shuhan Wang

2 Question 2: Lightning Round — Short Answer [14 marks total]

2.1 2(a) [6 marks]

Give two reasons to prefer reverse-mode automatic differentiation over forward-mode in training deep learning models, and one example of a setting other than in training deep learning models where forward-mode might be preferable instead.

Answer

两个偏好 **reverse-mode** 的理由:

理由一: 计算效率。 Deep learning 的典型结构是: 大量输入参数 θ ($|\theta|$ 可达数百万甚至数十亿), 但输出只有一个标量 loss $\mathcal{L}$ 。Reverse-mode autodiff 一次 backward pass 即可计算 $\nabla_{\theta}\mathcal{L}$ (对所有参数的梯度), 计算量约为 forward pass 的常数倍 (通常 2-3 倍)。而 forward-mode 每次只能计算关于一个参数方向的方向导数 (Jacobian-vector product), 因此需要 $|\theta|$ 次 forward pass 才能获得完整的梯度向量, 这在参数量巨大时不可行。

理由二: Reverse-mode 自然产生所需的 Jacobian 行。 在 deep learning 中, 我们需要的是标量损失对所有参数的梯度 $\frac{\partial \mathcal{L}}{\partial \theta_j}$, 即 Jacobian 的一行 (因为输出是标量)。Reverse-mode 恰好高效地计算 vector-Jacobian product (VJP), 一次即可得到整行。Forward-mode 计算的是 Jacobian-vector product (JVP), 一次只得到一列, 与我们的需求不匹配。

一个 **forward-mode** 更优的场景:

当输入维度很低、输出维度很高时, forward-mode 更高效。例如: 在 sensitivity analysis 中对少量参数 (如 2-3 个 ODE 初始条件) 求解一个高维输出向量的灵敏度。一般规则是: 若输出维度 $\gg$ 输入维度, forward-mode 所需 pass 数更少。

2.2 2(b) [4 marks]

Give one advantage and one disadvantage of using Markov chain Monte Carlo (MCMC) to estimate the posterior over weights in a Bayesian neural network.

Answer

优势: MCMC 理论上是 **asymptotically exact** 的。当 Markov chain 运行足够长时间后, 采样分布收敛到真实的 posterior $p(\theta|\mathcal{D})$, 不需要对 posterior 的形状做任何假设 (如 Gaussian、factorised 等)。这意味着 MCMC 可以捕捉 posterior 的所有特征, 包括多模态、非对称性、重尾性等。

劣势: MCMC 在 BNN 中计算代价极高且难以判断收敛:

1. 每一步 MH acceptance 需要在整个数据集上计算 likelihood, 无法像 SGD 那样使用 minibatch。
2. BNN 的参数空间维度极高 (百万级), MCMC chain 的 mixing time 非常长, effective sample size 极低。

3. 难以诊断 chain 是否已经 converge (burn-in 时间未知)。

2.3 2(c) [4 marks]

A “deep ensemble” is a collection of trained deep learning models, each with weights optimized by gradient descent from a different initialization. In a Bayesian interpretation of the ensemble as approximate posterior inference, describe

- how you would evaluate the posterior predictive distribution on a new test point; and
- what the form the predictive distribution might have in a binary classification problem.

Answer

2(c)(i):

设 ensemble 有 M 个模型, 各自的权重为 $\theta_1, \theta_2, \dots, \theta_M$ 。在 Bayesian 解释下, 每个 θ_k 可以看作从 approximate posterior $q(\theta|\mathcal{D})$ 中的一个 (隐式的) sample。

对于新测试点 x_0 , posterior predictive distribution 通过 Monte Carlo 近似计算:

$$p(y_0|x_0, \mathcal{D}) = \int p(y_0|x_0, \theta) p(\theta|\mathcal{D}) d\theta \approx \frac{1}{M} \sum_{k=1}^M p(y_0|x_0, \theta_k)$$

即将每个 ensemble member 的预测分布取平均。

2(c)(ii):

在 binary classification 中, 每个 ensemble member 输出一个概率:

$$p_k = p(y_0 = 1|x_0, \theta_k) = \sigma(f_{\theta_k}(x_0))$$

因此 posterior predictive 为:

$$p(y_0 = 1|x_0, \mathcal{D}) \approx \frac{1}{M} \sum_{k=1}^M \sigma(f_{\theta_k}(x_0)) = \frac{1}{M} \sum_{k=1}^M p_k$$

这是 M 个 Bernoulli 分布的 **mixture of Bernoullis**。每个分量 $p(y_0|x_0, \theta_k) = \text{Bernoulli}(p_k)$, 混合权重均匀 $1/M$ 。注意这个 mixture 本身不是 Bernoulli 分布 (除非所有 p_k 相等)。

3 Question 3: Deep Learning Architectures [15 marks total]

层定义: $h = g(Wx + b)$, 其中 W, b 是权重, x 是输入, $g(\cdot)$ 是 elementwise function。

3.1 3(a) [2 marks]

If $x \in \mathbb{R}^D$ and $h \in \mathbb{R}^M$, how many parameters does this layer have?

Answer

权重矩阵 $W \in \mathbb{R}^{M \times D}$: $M \times D$ 个参数; 偏置向量 $b \in \mathbb{R}^M$: M 个参数。

$$\text{Total parameters} = MD + M = M(D + 1)$$

3.2 3(b) [6 marks]

Consider three possible choices of function $g(\cdot)$: the ReLU $g(z) = \max(z, 0)$, the sigmoid $g(z) = \tanh(z)$, and the identity $g(z) = z$. For each of these three options, give one advantage and one disadvantage of this choice.

Answer

ReLU: $g(z) = \max(z, 0)$

- 优势: 计算极其高效 (只需比较和赋零), 且在 $z > 0$ 区域梯度恒为 1, 不会出现 vanishing gradient 问题, 有利于训练深层网络。
- 劣势: 在 $z < 0$ 区域梯度为 0 (dead neuron 问题)。如果某个 neuron 的 pre-activation 对所有训练样本都为负, 该 neuron 永远不会被更新。此外 ReLU 在 $z = 0$ 处不可微。

Sigmoid (tanh): $g(z) = \tanh(z)$

- 优势: 输出有界, 在 $(-1, 1)$ 范围内, 且关于原点对称 (zero-centered), 有利于后续层的学习。是平滑 (处处可微) 的非线性函数。
- 劣势: 在 $|z|$ 很大时, $\tanh'(z) \rightarrow 0$ (saturation), 导致 vanishing gradient 问题。在深层网络中, 梯度会在多次乘以接近零的导数后指数衰减。

Identity: $g(z) = z$

- 优势: 最简单的选择, 梯度恒为 1, 完全不存在 vanishing 或 exploding gradient 的问题 (就激活函数本身而言)。
- 劣势: 没有引入任何非线性, 导致多层叠加等价于单个线性层: $W_2(W_1x + b_1) + b_2 = W_2W_1x + (W_2b_1 + b_2)$ 。因此 identity activation 无法增加模型的表达能力 (expressiveness)。

3.3 3(c)(i) [4 marks]

Suppose we stack two layers: $h_1 = g(W_1x + b_1)$, $h_2 = g(W_2h_1 + b_2)$, with $x \in \mathbb{R}^D$, $h_1, h_2 \in \mathbb{R}^M$. How many parameters are in these two layers combined? What might be an advantage of using two layers, rather than one single layer with more hidden units?

Answer

参数数量：第一层 $W_1 \in \mathbb{R}^{M \times D}$, $b_1 \in \mathbb{R}^M$, 共 $M(D + 1)$ 个参数。第二层 $W_2 \in \mathbb{R}^{M \times M}$, $b_2 \in \mathbb{R}^M$, 共 $M(M + 1)$ 个参数。

$$\text{Total} = M(D + 1) + M(M + 1) = M(D + M + 2)$$

使用两层的优势： 两层网络 (with nonlinear activation) 可以学习层次化的、组合式的特征表示 (hierarchical feature representations)。第一层学习低级特征，第二层在此基础上组合出高级特征。

与使用单层但更多 hidden units 相比，两层结构的优势：某些函数用深层网络只需 polynomial 数量的 neurons 即可表示，而用单隐层网络则需要 exponential 数量 (depth-width tradeoff)。深层网络可以通过组合简单特征来表示复杂模式，具有更好的 inductive bias。

3.4 3(c)(ii) [3 marks]

Suppose you want to add a skip connection which goes directly from x to h_2 , bypassing h_1 . How would you modify the two equations above? You can add a single additional parameter matrix, V .

Answer

保持第一层不变，修改第二层如下：

$$h_1 = g(W_1x + b_1) \tag{1}$$

$$h_2 = g(W_2h_1 + Vx + b_2) \tag{2}$$

其中 $V \in \mathbb{R}^{M \times D}$ 是新引入的参数矩阵，将原始输入 x 直接线性变换后加入到第二层的 pre-activation 中。

注意：需要 V 而不能直接用 $h_2 = g(W_2h_1 + b_2) + x$ ，是因为 $x \in \mathbb{R}^D$ 和 $h_2 \in \mathbb{R}^M$ 可能维度不同，所以需要 V 来做维度转换。

3.5 3(c)(iii) [2 marks]

Why would you add this skip connection — what might doing this accomplish?

Answer

1. 缓解 **vanishing gradient** 问题: 梯度可以通过 skip connection 直接从 h_2 流向 x (路径 $\frac{\partial h_2}{\partial x}$ 中包含通过 V 的直接分量), 绕过中间层 h_1 的非线性变换。这确保了即使中间层的梯度非常小, 梯度信号仍然可以有效地传播到早期层。
2. 提供恒等映射的 **baseline**: 如果网络发现第一层的变换没有帮助, 它可以学习令 $W_2 \approx 0$, 让 $h_2 \approx g(Vx + b_2)$, 直接绕过第一层。这使得增加深度不会比浅层差, 降低了优化难度。

4 Question 4: Generative Models and Missing Data [35 marks total]

设 $x_1, \dots, x_N$ 为 N 张训练图像。对于测试图像 x , x^v 表示可见像素, x^m 表示缺失像素。目标是从 $p(x^m|x^v)$ 中采样或估计缺失像素。

4.1 4(a)(i) [3 marks]

Suppose we had access to a trained probabilistic model $p(x)$ which is tractable, in the sense that we can evaluate the probability for any input x . Give two examples of generative models we discussed where this is possible, including a deep generative model if possible.

Answer

例 1 (非深度模型): Gaussian mixture model (GMM)。 对于任意输入 x , 可以直接计算:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \Sigma_k)$$

每个分量的密度都可以解析计算, 求和后即得到 tractable 的 $p(x)$ 。

例 2 (深度生成模型): Normalising flow。 通过一系列可逆变换 $f = f_L \circ \dots \circ f_1$ 将简单的基分布 $p_0(z)$ 映射到复杂分布。对于任意 x :

$$p(x) = p_0(f^{-1}(x)) \left| \det \frac{\partial f^{-1}}{\partial x} \right|$$

由于变换设计为 Jacobian determinant 可以高效计算, 所以 $p(x)$ 是 tractable 的。

(另一个可接受的答案是 autoregressive model, 如 PixelCNN, 其中 $p(x) = \prod_d p(x_d|x_{<d})$ 。)

4.2 4(a)(ii) [5 marks]

Describe a possible Metropolis-Hastings MCMC algorithm to sample from $p(x^m|x^v)$. Include the acceptance ratio, and a description of any proposal distributions.

Answer

利用 Bayes' rule: $p(x^m|x^v) \propto p(x^v, x^m) = p(x)$ (因为 $p(x^v)$ 是与 x^m 无关的常数)。

MH 算法:

1. **初始化:** 选择 missing pixels 的初始值 x_0^m (例如随机初始化)。

2. **在每一步 t :**

Proposal: 从 proposal distribution 中采样新的 missing pixel 值 x'^m 。使用 random walk proposal:

$$q(x'^m|x_t^m) = \mathcal{N}(x'^m|x_t^m, \sigma^2 I)$$

构造完整图像: $x' = (x^v, x'^m)$, $x_t = (x^v, x_t^m)$ 。

计算 **acceptance ratio**: 由于 random walk proposal 是对称的 ($q(x'^m|x_t^m) = q(x_t^m|x'^m)$), 简化为:

$$\alpha = \min \left(1, \frac{p(x')}{p(x_t)} \right) = \min \left(1, \frac{p(x^v, x'^m)}{p(x^v, x_t^m)} \right)$$

以概率 α 接受 $x_{t+1}^m = x'^m$, 否则 $x_{t+1}^m = x_t^m$ 。

3. 丢弃 burn-in 样本, 保留后续样本作为 $p(x^m|x^v)$ 的近似采样。

4.3 4(a)(iii) [2 marks]

Do you think this is a good approach to estimating the missing pixels in the test image?

Answer

这个方法在理论上是正确的 (MCMC 是 asymptotically exact), 但在实际应用中效果可能不好:

1. **高维 mixing 缓慢**: missing pixels x^m 通常是高维向量 (可能有数千个像素), random walk proposal 在高维空间中 acceptance rate 极低, chain 的 mixing 非常慢。
2. **Proposal 设计困难**: 简单的 random walk 不了解图像的结构 (如纹理、边缘), 每次只做小的随机扰动, 很难高效地探索 $p(x^m|x^v)$ 的 typical set。

因此虽然方法原理正确, 但由于 missing pixel 维度高, 实际效率可能很差。

4.4 4(b)(i) [3 marks]

Would the MCMC scheme you described in part (a) work for sampling from $p_\theta(x^m|x^v)$, where $p_\theta(x)$ is defined using this latent variable model (VAE)? Why or why not?

Answer

不能直接使用。

原因在于 part (a) 中的 MH 算法需要能够逐点计算 $p_\theta(x)$ (即给定 x , 返回其概率值), 但在 VAE 的 latent variable model 中:

$$p_\theta(x) = \int p_\theta(x|z) p(z) dz$$

这个积分关于 latent variable z 是 **intractable** 的 (正是因为这个积分不可解析, 我们才需要引入 variational inference)。

因此我们无法精确计算 acceptance ratio 中的 $p_\theta(x')$ 和 $p_\theta(x_t)$, part (a) 的 MH scheme 无法直接应用。

4.5 4(b)(ii) [5 marks]

Consider an alternative MCMC scheme for latent variable models, which targets $p_\theta(x^m, z|x^v)$. That is, it draws samples of both z and x^m , conditioned on the visible x^v . Describe such an approach: what would the Metropolis-Hastings acceptance ratio be, and what would be good choices of proposal distributions for x^m and z ?

Answer

现在我们在扩展的空间 (x^m, z) 上做 MCMC, target distribution 为:

$$p_\theta(x^m, z|x^v) \propto p_\theta(x^m, z, x^v) = p_\theta(x|z)p(z)$$

其中 $x = (x^v, x^m)$ 。这里 $p_\theta(x|z)$ 和 $p(z)$ 都是 tractable 的。

MH 算法 (联合 proposal):

在每一步 t , 给定当前状态 (x_t^m, z_t) , propose 新的 (x'^m, z') 。Acceptance ratio:

$$\alpha = \min \left(1, \frac{p_\theta(x'|z') p(z') q(x_t^m, z_t|x'^m, z')}{p_\theta(x_t|z_t) p(z_t) q(x'^m, z'|x_t^m, z_t)} \right)$$

其中 $x' = (x^v, x'^m)$, $x_t = (x^v, x_t^m)$ 。

Proposal 的好选择:

- 对 z 的 **proposal**: 利用 inference network $q_\phi(z|x)$ 。给定当前完整图像 $x_t = (x^v, x_t^m)$, 从 $q_\phi(z'|x_t)$ 中采样 z' 。这是一个 informed proposal, 利用了训练好的 encoder。
- 对 x^m 的 **proposal**: 利用 decoder $p_\theta(x|z')$ 。给定新采样的 z' , 从 decoder 的条件分布中采样 missing pixel 值 x'^m 。这确保提议的 x'^m 与 z' 一致且在数据流形上。

4.6 4(b)(iii) [2 marks]

Does this alternative MCMC scheme draw samples from $p_\theta(x^m|x^v)$? Why or why not?

Answer

是的, 可以。

虽然 MCMC chain 的 target distribution 是 joint distribution $p_\theta(x^m, z|x^v)$, 但从 joint 中采样后, 只需丢弃 z 样本、保留 x^m 样本, 得到的 x^m 样本即服从 marginal distribution:

$$p_\theta(x^m|x^v) = \int p_\theta(x^m, z|x^v) dz$$

这是 marginalization 的标准性质: joint distribution 的 marginal 就是我们需要的目标分布。所以只要 MCMC chain 正确收敛到 $p_\theta(x^m, z|x^v)$, 丢弃 z 后的 x^m 样本就是 $p_\theta(x^m|x^v)$ 的有效样本。

4.7 4(c)(i) [7 marks]

Derive a tractable objective function for gradient-based optimization of x^m , by treating the missing data as a latent variable, and derive a lower bound of $\log p_\theta(x^m|x^v)$. (Hint: remember how we derived the ELBO!)

Answer

我们想最大化 $\log p_\theta(x^m|x^v)$ 。注意：

$$\log p_\theta(x^m|x^v) = \log p_\theta(x) - \log p_\theta(x^v)$$

其中 $x = (x^v, x^m)$ ，而 $\log p_\theta(x^v)$ 不依赖于 x^m 。因此最大化 $\log p_\theta(x^m|x^v)$ 等价于最大化 $\log p_\theta(x)$ 。

对 $\log p_\theta(x)$ 应用标准 ELBO 推导，引入 variational distribution $q_\phi(z|x)$ ：

$$\log p_\theta(x) = \log \int p_\theta(x|z) p(z) dz \quad (3)$$

$$= \log \int \frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} q_\phi(z|x) dz \quad (4)$$

$$\geq \int q_\phi(z|x) \log \frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} dz \quad (\text{Jensen's inequality}) \quad (5)$$

$$= \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \parallel p(z)) \quad (6)$$

定义 ELBO：

$$\mathcal{L}(x^m) = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \parallel p(z))$$

其中 $x = (x^v, x^m)$ ， x^v 固定， x^m 是要优化的变量。

由于 $\log p_\theta(x) \geq \mathcal{L}(x^m)$ ，且 $\log p_\theta(x^m|x^v) = \log p_\theta(x) - \underbrace{\log p_\theta(x^v)}_{\text{const w.r.t. } x^m}$ ，所以：

$$\log p_\theta(x^m|x^v) \geq \mathcal{L}(x^m) - \log p_\theta(x^v)$$

$\mathcal{L}(x^m)$ 是 $\log p_\theta(x^m|x^v)$ 的 lower bound（差一个与 x^m 无关的常数和一個非负 KL 项）。最终目标： $\max_{x^m} \mathcal{L}(x^m)$ 。

4.8 4(c)(ii) [3 marks]

Describe how you would optimize this objective using gradient-based methods, and write down an estimator for the gradient of this objective.

Answer

使用 **reparameterization trick** 来估计 $\nabla_{x^m} \mathcal{L}(x^m)$ 。

令 $q_\phi(z|x) = \mathcal{N}(z|\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$ 。Reparameterize:

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

注意 $x = (x^v, x^m)$ ，所以 μ_ϕ 和 σ_ϕ 都是 x^m 的函数（通过 encoder network）。

梯度估计器为：

$$\nabla_{x^m} \mathcal{L}(x^m) \approx \frac{1}{S} \sum_{s=1}^S \nabla_{x^m} \left[\log p_\theta(x|z^{(s)}) - \log \frac{q_\phi(z^{(s)}|x)}{p(z^{(s)})} \right]$$

其中 $z^{(s)} = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon^{(s)}$ ， $\epsilon^{(s)} \sim \mathcal{N}(0, I)$ 。

优化过程：使用 gradient ascent（或 Adam 等优化器），将 x^m 作为可优化的连续变量：

$$x^m \leftarrow x^m + \eta \nabla_{x^m} \mathcal{L}(x^m)。$$

4.9 4(c)(iii) [5 marks]

As an alternative approach, suppose we directly tried to estimate the gradient $\nabla_{x^m} p(x^m|x^v)$. Can you suggest a Monte Carlo estimator for this gradient? (Hint: consider a likelihood weighting or importance sampling approach!)

Answer

我们要估计 $\nabla_{x^m} p_\theta(x^m|x^v)$ 。由于 $p_\theta(x^v)$ 不依赖于 x^m ：

$$\nabla_{x^m} p_\theta(x^m|x^v) = \frac{1}{p_\theta(x^v)} \nabla_{x^m} p_\theta(x) = \frac{1}{p_\theta(x^v)} \int \nabla_{x^m} p_\theta(x|z) p(z) dz$$

利用 $\nabla_{x^m} p_\theta(x|z) = p_\theta(x|z) \nabla_{x^m} \log p_\theta(x|z)$ ：

$$= \frac{1}{p_\theta(x^v)} \int p_\theta(x|z) \nabla_{x^m} \log p_\theta(x|z) p(z) dz$$

引入 importance sampling proposal $q_\phi(z|x)$ ：

$$\begin{aligned} &= \frac{1}{p_\theta(x^v)} \int \frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} \nabla_{x^m} \log p_\theta(x|z) q_\phi(z|x) dz \\ &= \frac{1}{p_\theta(x^v)} \mathbb{E}_{q_\phi(z|x)} [w(z) \nabla_{x^m} \log p_\theta(x|z)] \end{aligned}$$

其中 importance weight 为 $w(z) = \frac{p_\theta(x|z) p(z)}{q_\phi(z|x)}$ 。

由于 $p_\theta(x^v)$ 也是 intractable 的，使用 **self-normalized importance sampling**：

$$\nabla_{x^m} \log p_\theta(x^m|x^v) \approx \frac{\sum_{s=1}^S \bar{w}^{(s)} \nabla_{x^m} \log p_\theta(x|z^{(s)})}{\sum_{s=1}^S \bar{w}^{(s)}}$$

其中 $z^{(s)} \sim q_\phi(z|x)$ ，未归一化的 importance weights 为：

$$\bar{w}^{(s)} = \frac{p_\theta(x|z^{(s)}) p(z^{(s)})}{q_\phi(z^{(s)}|x)}$$

这个 self-normalized IS 估计器避免了计算 $p_\theta(x^v)$ ，是有偏的但 consistent 的。 $q_\phi(z|x)$ (encoder) 是一个自然的 proposal choice，因为它近似 posterior $p(z|x)$ ，使得 importance weights 的方差较小。

Shuhan Wang

5 Question 5: Linearizing Predictions [20 marks total]

模型设定:

$$\theta \sim \mathcal{N}(0, \alpha^{-1}I) \quad (7)$$

$$y_i|x_i \sim \mathcal{N}(f_\theta(x_i), \beta^{-1}) \quad (8)$$

其中 f_θ 是 deep network。Approximate posterior: $q(\theta|\mathcal{D}) \approx \mathcal{N}(\theta|\mu, \Sigma)$ 。

5.1 5(a) [5 marks]

For a new test input x_0 with unknown label y_0 , write out the predictive distribution $p(y_0|x_0, \mathcal{D}, \alpha, \beta)$ as a function of our posterior approximation $q(\theta|\mathcal{D})$. [Note: this will involve an intractable integral, and does not have a closed form; we are just looking for the general expression.]

Answer

Posterior predictive distribution 定义为:

$$p(y_0|x_0, \mathcal{D}, \alpha, \beta) = \int p(y_0|x_0, \theta, \beta) p(\theta|\mathcal{D}, \alpha, \beta) d\theta$$

用 approximate posterior $q(\theta|\mathcal{D})$ 代替 true posterior:

$$p(y_0|x_0, \mathcal{D}, \alpha, \beta) \approx \int \mathcal{N}(y_0|f_\theta(x_0), \beta^{-1}) \mathcal{N}(\theta|\mu, \Sigma) d\theta$$

这个积分是 **intractable** 的, 因为 $f_\theta(x_0)$ 是一个 deep neural network, 是 θ 的高度非线性函数。即使 likelihood 和 posterior approximation 都是 Gaussian, f_θ 的非线性使得积分无法解析。

关键区别在于 Bayesian linear regression 中 $f_\theta(x) = \theta^\top \phi(x)$ 是 θ 的线性函数, 所以 Gaussian-Gaussian 积分可以解析完成。但这里 f_θ 是 deep network, θ 出现在非线性激活函数的内部, 无法简化。

5.2 5(b)(i) [5 marks]

Provide a derivation of the expression:

$$p(y_0|x_0, \mathcal{D}, \alpha, \beta) \approx \mathcal{N}(y_0|f_\mu(x_0), \beta^{-1} + g(x_0)^\top \Sigma g(x_0))$$

where $g(x_0) = \nabla_\theta f_\theta(x_0)$ evaluated at $\theta = \mu$.

Answer

核心思想: 对 $f_\theta(x_0)$ 在 posterior mean $\theta = \mu$ 处做一阶 Taylor 展开 (linearization)。

Step 1: Taylor 展开

$$f_{\theta}(x_0) \approx f_{\mu}(x_0) + \nabla_{\theta} f_{\theta}(x_0) \Big|_{\theta=\mu}^{\top} (\theta - \mu) = f_{\mu}(x_0) + g(x_0)^{\top} (\theta - \mu)$$

其中 $g(x_0) = \nabla_{\theta} f_{\theta}(x_0) \Big|_{\theta=\mu}$ 。

Step 2: 代入 likelihood

$$p(y_0|x_0, \theta) = \mathcal{N}(y_0|f_{\theta}(x_0), \beta^{-1}) \approx \mathcal{N}(y_0|f_{\mu}(x_0) + g(x_0)^{\top} (\theta - \mu), \beta^{-1})$$

Step 3: 对 $q(\theta|\mathcal{D}) = \mathcal{N}(\theta|\mu, \Sigma)$ 积分

在 linearized 模型下, y_0 是 θ 的仿射函数加上 Gaussian noise:

$$y_0 = f_{\mu}(x_0) + g(x_0)^{\top} (\theta - \mu) + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \beta^{-1})$$

因为 $\theta \sim \mathcal{N}(\mu, \Sigma)$, 所以 $g(x_0)^{\top} (\theta - \mu) \sim \mathcal{N}(0, g(x_0)^{\top} \Sigma g(x_0))$ 。

ϵ 和 θ 独立, 因此 y_0 是两个独立 Gaussian 的和:

$$\mathbb{E}[y_0] = f_{\mu}(x_0) + g(x_0)^{\top} \underbrace{\mathbb{E}[\theta - \mu]}_{=0} + \underbrace{\mathbb{E}[\epsilon]}_{=0} = f_{\mu}(x_0) \quad (9)$$

$$\text{Var}[y_0] = g(x_0)^{\top} \Sigma g(x_0) + \beta^{-1} \quad (10)$$

因此:

$$p(y_0|x_0, \mathcal{D}, \alpha, \beta) \approx \mathcal{N}\left(y_0 \mid f_{\mu}(x_0), \beta^{-1} + g(x_0)^{\top} \Sigma g(x_0)\right)$$

5.3 5(b)(ii) [3 marks]

Under what circumstances will this be a good approximation to the predictive distribution? Outline the assumptions made for this approximation, and give an example of when these assumptions might be violated.

Answer

该近似基于以下假设:

假设 1: Posterior 集中在 μ 附近。 Taylor 展开要求 θ 在 μ 附近时 $f_{\theta}(x_0)$ 近似线性, 即 posterior 的 covariance Σ 足够小, 使得 θ 的采样值不会偏离 μ 太远。如果 Σ 很大 (posterior 很宽), 高阶项不可忽略, linearization 就不准确。

假设 2: $f_{\theta}(x_0)$ 在 μ 附近关于 θ 近似线性。 如果 network function f_{θ} 关于 θ 高度非线性 (例如在 loss landscape 的高曲率区域), 一阶 Taylor 展开的误差就大。

假设会被违反的例子:

- **小数据场景:** 数据量少时 posterior 很宽 (Σ 的 eigenvalue 很大), θ 的样本可能远离 μ , linearization 不准确。
- **ReLU 网络:** 在 θ 变化导致某些 neuron 激活状态切换时, f_{θ} 的分段线性结构意味着微

小的参数变化可能导致 gradient 不连续，使得局部线性假设失效。

5.4 5(b)(iii) [2 marks]

We introduced this approach in class for use with Laplace approximations. Could you use this with any Gaussian approximation to the posterior (e.g. found by variational Bayes)? Why or why not?

Answer

可以。Linearized prediction 的推导只要求 posterior approximation 是 Gaussian 形式 $q(\theta|\mathcal{D}) = \mathcal{N}(\theta|\mu, \Sigma)$ ，然后对 f_θ 在 μ 处做 Taylor 展开，利用 Gaussian 积分的解析性得到 closed-form predictive。

这个推导过程对 μ 和 Σ 的来源没有任何要求。无论 Gaussian approximation 是通过以下哪种方式得到的：

- Laplace approximation: $\mu = \theta_{\text{MAP}}$, $\Sigma = (-\nabla^2 \log p(\theta|\mathcal{D})|_{\theta_{\text{MAP}}})^{-1}$
- Variational Bayes: μ, Σ 通过最大化 ELBO 得到
- 其他方法（如 SWAG）

只要最终给出 (μ, Σ) 的 Gaussian posterior，linearized prediction 公式都适用。

5.5 5(c)(i) [2 marks]

Provide an interpretation of the two terms: β^{-1} , and $g(x_0)^\top \Sigma g(x_0)$.

Answer

Posterior predictive variance 分解为：

$$\underbrace{\beta^{-1}}_{\text{aleatoric uncertainty}} + \underbrace{g(x_0)^\top \Sigma g(x_0)}_{\text{epistemic uncertainty}}$$

β^{-1} — **Aleatoric uncertainty**（数据噪声）：这是 observation noise variance，来自 likelihood $p(y|x, \theta) = \mathcal{N}(y|f_\theta(x), \beta^{-1})$ 中的固有噪声。即使我们完全确定模型参数（ $\Sigma \rightarrow 0$ ），这个噪声仍然存在。它反映了数据本身的不可约随机性。

$g(x_0)^\top \Sigma g(x_0)$ — **Epistemic uncertainty**（模型不确定性）：这个量捕捉了由于对参数 θ 的不确定性（ Σ ）所传播到预测值 $f_\theta(x_0)$ 上的不确定性。 $g(x_0) = \nabla_\theta f_\theta(x_0)$ 是 network output 对参数的灵敏度（sensitivity）， Σ 是参数的 posterior covariance。通过 error propagation（一阶近似），参数不确定性 Σ 通过 g 映射为预测不确定性。当数据量增加时， $\Sigma \rightarrow 0$ ，这一项趋于零。

5.6 5(c)(ii) [3 marks]

Suppose instead of a fixed value of β , the likelihood variance were input-dependent, and specified by another deep learning model $\beta_\psi(x)$ where ψ are trainable parameters. How does this change your interpretation?

Answer

如果令 likelihood variance 为 input-dependent:

$$p(y|x, \theta) = \mathcal{N}(y|f_\theta(x), \beta_\psi(x)^{-1})$$

那么 predictive variance 变为:

$$\text{Var}[y_0|x_0] = \beta_\psi(x_0)^{-1} + g(x_0)^\top \Sigma g(x_0)$$

解释的变化:

1. **Aleatoric uncertainty 变为 input-dependent:** $\beta_\psi(x_0)^{-1}$ 现在是输入 x_0 的函数, 反映了不同输入位置处数据噪声水平的差异。例如, 在某些区域数据可能天然更嘈杂 (如图像的模糊区域、传感器精度较低的测量区域), 而在其他区域噪声较小。这被称为 **heteroscedastic noise model**。
2. **可以区分两种不确定性来源:** 在固定 β 的模型中, 如果某个区域预测不确定性高, 我们无法区分是因为数据噪声大 (aleatoric) 还是因为训练数据少 (epistemic)。而 input-dependent $\beta_\psi(x)$ 允许模型为每个输入分别估计 aleatoric 和 epistemic 分量, 从而提供更精细的不确定性分解。
3. **实际意义:** 如果某个预测的高不确定性主要来自 epistemic 部分 ($g(x_0)^\top \Sigma g(x_0)$ 大), 说明可以通过收集更多类似数据来改善; 如果主要来自 aleatoric 部分 ($\beta_\psi(x_0)^{-1}$ 大), 则说明数据本身噪声大, 无法通过更多数据减少, 可能需要改进数据采集方式。