

COMP0171 Bayesian Deep Learning — 2025 Past Paper

Model Answers

Contents

1	Question 1: True/False [14 marks total]	2
2	Question 2: Short Answer [26 marks total]	4
3	Question 3: Proposal Distributions [15 marks total]	6
4	Question 4: Bayesian VAE [25 marks total]	7
5	Question 5: Gradients, Autodiff, Recursion [20 marks total]	9

1 Question 1: True/False [14 marks total]

1(a) [2 marks]

Statement: Stochastic gradient Langevin Dynamics (SGLD) is typically used in big data settings, despite being an inexact sampler, as it only uses a small subset of the data on every iteration.

True.

SGLD 的核心思想是将 Langevin dynamics 与 stochastic gradient 结合。标准 MCMC (如 MH) 每步需遍历全部数据来计算 acceptance ratio, 在大数据场景下成本极高。SGLD 用 minibatch gradient 代替 full-batch gradient 来近似 $\nabla_{\theta} \log \pi(\theta)$, 并跳过 accept/reject step。更新公式为:

$$\theta^{(t+1)} = \theta^{(t)} + \eta \nabla_{\theta} \log \pi(\theta^{(t)}) + \sqrt{2\eta} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

跳过 accept/reject 使其成为 **inexact sampler**, 但在 $\eta \rightarrow 0$ 极限下趋于精确。使用有限 η 和 minibatch 噪声, 它是一种近似但高效的采样方法, 特别适合 big data。

1(b) [2 marks]

Statement: Averages of samples from MCMC can be used to compute posterior expectations and estimate marginal likelihoods.

False.

MCMC 样本可以计算 posterior expectations: $\mathbb{E}_{p(\theta|\mathcal{D})}[f(\theta)] \approx \frac{1}{S} \sum_{s=1}^S f(\theta^{(s)})$ 。但 MCMC 不能直接估计 marginal likelihood $p(\mathcal{D})$ 。原因: MCMC 采样时 normalizing constant $p(\mathcal{D})$ 在 acceptance ratio 中消去:

$$\alpha = \min \left(1, \frac{\gamma(\theta') q(\theta|\theta')}{\gamma(\theta) q(\theta'|\theta)} \right), \quad \gamma(\theta) = p(\mathcal{D}|\theta) p(\theta),$$

MCMC 从不需要也不计算 $p(\mathcal{D})$ 。估计 marginal likelihood 需要 importance sampling、thermodynamic integration 等额外方法。

1(c) [2 marks]

Statement: A GP with linear kernel has the same predictive distribution as Bayesian linear regression, but requires less computation time and memory.

False.

前半句正确: GP with linear kernel $k(x, x') = x^{\top} x'$ 与 Bayesian linear regression 给出相同 predictive distribution。但后半句错误。GP 的计算 $O(N^3)$ 、内存 $O(N^2)$ ($N \times N$ kernel matrix)。Bayesian linear regression 的计算 $O(D^3)$ 、内存 $O(D^2)$ ($D \times D$ matrix)。当 $N > D$ 时 (通常如此), **Bayesian linear regression** 更快更省内存。

1(d) [2 marks]

Statement: Low confidence on rare dog breeds is epistemic uncertainty, capturable by BNN.

True.

低置信度源于训练数据不足 (rare breeds 样本极少), 这正是 **epistemic uncertainty**: 因知识不足而产生的不确定性, 可通过更多数据减少。BNN 通过 posterior $p(\theta|\mathcal{D})$ 捕捉:

$$p(y|x, \mathcal{D}) = \int p(y|x, \theta) p(\theta|\mathcal{D}) d\theta.$$

对数据少的类别, posterior 较宽 $\Rightarrow$ predictive distribution 分散 (低置信度)。这不是 aleatoric uncertainty (更多 rare breed 图片会提高置信度)。

1(e) [2 marks]

Statement: Forward-mode autodiff is preferable to reverse-mode for many outputs, few inputs.

True.

Forward mode: 一次 pass 计算对一个输入的导数, 成本 $\propto D_{in}$ 。Reverse mode: 一次 pass 计算一个输出对所有参数的梯度, 成本 $\propto D_{out}$ 。当 $D_{out} \gg D_{in}$ 时 forward mode 更高效。例: $f: \mathbb{R} \rightarrow \mathbb{R}^M$ 的 Jacobian, forward mode 一次 pass, reverse mode 需 M 次。

1(f) [2 marks]

Statement: Convolutional features are invariant to small translations.

False.

卷积层是 **equivariant** (等变) 而非 **invariant** (不变)。设 shifted input $x'_{d+1} = x_d$, 则

$$h'_{d+1} = \sigma(w_1 x'_d + w_2 x'_{d+1} + w_3 x'_{d+2}) = \sigma(w_1 x_{d-1} + w_2 x_d + w_3 x_{d+1}) = h_d.$$

输出也平移了一步 — equivariance, 不是 invariance。Invariance 需要额外 pooling。

1(g) [2 marks]

Statement: Active learning not possible for spam filter since emails are discrete.

False.

Active learning 完全适用于离散数据。核心思想是基于 model uncertainty 智能选择标注样本, 与输入是否连续无关。在 spam filter 中: 有大量未标注 emails, active learning 选择 high-uncertainty 的 email 优先标注。适用条件: (1) 有 unlabelled data pool, (2) labelling 有成本, (3) 模型能量化 uncertainty — 全不要求连续输入。

2 Question 2: Short Answer [26 marks total]

2(a) U-Net vs Autoencoder [3 marks]

Skip connections 的作用：将 encoder 各层的 high-resolution spatial features 直接传递给 decoder 对应层。对 segmentation 等像素级任务，精细空间细节（边缘、位置）至关重要，bottleneck 会丢失这些信息，skip connections 恢复它们。

Autoencoder 为什么不加：核心目标是通过 bottleneck 强制学习 compressed representation。Skip connections 让信息绕过 bottleneck，网络可以“偷懒”直接复制，违背设计目的。

应该加吗？不应该。Bottleneck 是 autoencoder 的核心 feature 而非缺陷。

2(b)(i) Standard vs Bidirectional RNN [3 marks]

Standard RNN：只从左到右处理。 $h_t = g(W_h h_{t-1} + W_x x_t + b)$ ， h_t 仅包含 $x_1, \dots, x_t$ 的信息（past context）。

Bidirectional RNN：两个独立 RNN（forward + backward）， $h_t = [h_t^F; h_t^B]$ ，编码整个序列的上下文。

$$h_t^F = g(W_h^F h_{t-1}^F + W_x^F x_t + b^F), \quad h_t^B = g(W_h^B h_{t+1}^B + W_x^B x_t + b^B).$$

2(b)(ii) When bidirectional preferred? [2 marks]

当整个序列已完全可用且需要双向上下文时。例：sequence classification（sentiment analysis）、sequence labelling（NER、POS tagging）、machine translation encoder。

2(b)(iii) When standard preferred? [2 marks]

Autoregressive generation 任务：language modelling（预测 $p(x_{t+1}|x_{1:t})$ ）、text generation、online/streaming 处理。Bidirectional RNN 无法生成，因为生成时尚不知道未来 token。

2(c)(i) MAP objective [3 marks]

$$\theta_{\text{MAP}} = \arg \max_{\theta} \left\{ \sum_{i=1}^N \log p(y_i | x_i, \theta) + \log p(\theta) \right\}.$$

第一项 log-likelihood（数据拟合），第二项 log-prior（正则化）。 $\log p(\mathcal{D})$ 是常数，省略。

2(c)(ii) MAP = squared error + regulariser [3 marks]

展开 log-posterior（忽略常数项）：

$$\log p(\theta | \mathcal{D}) = \sum_{i=1}^N \left[-\frac{\beta}{2} (y_i - f(x_i, \theta))^2 \right] + \left[-\frac{\alpha}{2} \|\theta\|^2 \right] + \text{const.}$$

最大化等价于最小化：

$$\mathcal{L}(\theta) = \sum_{i=1}^N (y_i - f(x_i, \theta))^2 + \frac{\alpha}{\beta} \|\theta\|^2.$$

第一项 squared error loss, 第二项 L_2 regularisation, 强度 $\lambda = \alpha/\beta$ 。

2(c)(iii) “MAP is not Bayesian” [5 marks]

1. 点估计 vs 分布：MAP 只给出 point estimate θ_{MAP} (posterior mode), Bayesian approach 维护完整 posterior $p(\theta|\mathcal{D})$ 。

2. 不量化 **epistemic uncertainty**：MAP 预测确定性，无法表达参数不确定性。Bayesian 通过 $p(y|x, \mathcal{D}) = \int p(y|x, \theta)p(\theta|\mathcal{D}) d\theta$ 自然量化。

3. 不 **marginalise**：Bayesian 核心是 marginalisation (对 nuisance parameters 积分), MAP 只做 optimisation, 无法做 model comparison。

4. 过拟合风险：MAP 可能找到尖锐但非典型的 peak。Bayesian 通过对 posterior 积分实现 Occam's Razor。

总结：Bayesian = **posterior distribution + marginalisation**; MAP = regularised optimisation with prior。

2(d)(i) Are $\theta_1, \dots, \theta_K$ same or different? [2 marks]

不同。(1) Non-convex loss surface: 不同 initialisation $\rightarrow$ 不同 local minima。(2) Stochastic optimisation (Adam 的 minibatch randomness) 导致不同轨迹。这是 deep ensembles 的基础。

2(d)(ii) Evaluating $\Pr(y > 0|x)$ [3 marks]

每个模型 $p(y|x, \theta_k) = \mathcal{N}(y|f(x, \theta_k), \beta^{-1})$ 。Deep ensemble predictive:

$$\Pr(y > 0|x) \approx \frac{1}{K} \sum_{k=1}^K \Pr(y > 0|x, \theta_k) = \frac{1}{K} \sum_{k=1}^K \Phi\left(\frac{f(x, \theta_k)}{\beta^{-1/2}}\right),$$

其中 Φ 是标准正态 CDF。或简单地对每个 θ_k 采样 $y_k \sim \mathcal{N}(f(x, \theta_k), \beta^{-1})$, 统计 $y_k > 0$ 的比例。

3 Question 3: Proposal Distributions [15 marks total]

3(a)(i) Good IS proposal [2 marks]

(1) 覆盖 **target support**: $\pi(x) \neq 0 \Rightarrow q(x) > 0$ 。(2) 尾部至少一样重 (ideally heavier): 避免 importance weights 方差爆炸。(3) 形状接近 π : $q \propto \pi$ 时 weights 恒为常数, 方差为零。

3(a)(ii) Selecting μ, σ [2 marks]

$\mu = \arg \max_x \gamma(x)$ (匹配 target mode)。 σ : 用 Laplace approximation 的 Hessian 匹配曲率 $\sigma^2 \approx [-\nabla^2 \log \gamma|_{\mu}]^{-1}$, 适当加宽保证尾部覆盖。也可最小化 $\text{Var}_q[w(x)]$ 。

3(b)(i) Random-walk MH acceptance ratio [2 marks]

Gaussian random walk $q(x'|x) = \mathcal{N}(x'|x, \sigma^2)$ 是对称的 ($q(x'|x) = q(x|x')$), 因此:

$$\alpha(x', x) = \min\left(1, \frac{\gamma(x')}{\gamma(x)}\right).$$

Z 在 $\pi = \gamma/Z$ 的比值中消去。

3(b)(ii) Good random-walk proposal [2 marks]

关键是 step size σ 。太小: acceptance ≈ 1 但 mixing 慢 (步子太小)。太大: acceptance ≈ 0 (跳到低概率区)。理想 acceptance rate: 1D 约 44%, 高维约 23%, 平衡探索范围与接受率。

3(c)(i) Independent MH acceptance ratio [2 marks]

$q(x') = \mathcal{N}(x'|\mu, \sigma^2)$ 不依赖 x 。代入 MH 公式:

$$\alpha(x', x) = \min\left(1, \frac{\gamma(x')/q(x')}{\gamma(x)/q(x)}\right) = \min\left(1, \frac{w(x')}{w(x)}\right),$$

其中 $w(x) = \gamma(x)/q(x)$ 是 importance weight。

3(c)(ii) Optimal q and feasibility [2 marks]

$q = \pi \Rightarrow \gamma(x)/q(x) = Z$ 为常数 $\Rightarrow \alpha = 1$ 。但这是 **circular argument**: 能从 π 采样就不需要 MCMC 了。

3(d) Preference example [3 marks]

高维 **posterior** (如 BNN 权重, $d \gg 1$): 偏好 **random-walk MH**。Independent MH 的固定 proposal 在高维中无法有效覆盖 target (weights 方差指数增长 $\rightarrow$ acceptance $\rightarrow 0$, curse of dimensionality)。Random-walk 通过局部移动避免此问题。

反之, 若有好的全局近似 (如 Laplace/VI), **independent MH** 更好: 可做大跳跃, mixing 更快。

4 Question 4: Bayesian VAE [25 marks total]

4(a) Standard VAE ELBO [4 marks]

对 x_i , 引入 $q_\phi(z|x_i)$, 由 Jensen's inequality:

$$\begin{aligned}\log p(x_i|\theta) &= \log \int \frac{p(x_i|z, \theta)p(z)}{q_\phi(z|x_i)} q_\phi(z|x_i) dz \\ &\geq \mathbb{E}_{q_\phi(z|x_i)}[\log p(x_i|z, \theta)] - \text{KL}(q_\phi(z|x_i)||p(z)).\end{aligned}$$

求和:

$$\sum_{i=1}^N \log p(x_i|\theta) \geq \sum_{i=1}^N \left\{ \mathbb{E}_{q_\phi(z|x_i)}[\log p(x_i|z, \theta)] - \text{KL}(q_\phi(z|x_i)||p(z)) \right\}.$$

4(b) Joint distribution [2 marks]

$$p(\theta, z_{1:N}, x_{1:N}) = p(\theta) \prod_{i=1}^N p(z_i) p(x_i|z_i, \theta).$$

4(c) Fully Bayesian VAE ELBO [6 marks]

引入 $q(\theta, z_{1:N}|x_{1:N}) = q_\lambda(\theta) \prod_i q_\phi(z_i|x_i)$, 由 $\text{KL} \geq 0$:

$$\log p(x_{1:N}) \geq \mathbb{E}_{q(\theta, z_{1:N})} \left[\log \frac{p(\theta, z_{1:N}, x_{1:N})}{q(\theta, z_{1:N}|x_{1:N})} \right].$$

展开并整理:

$$\mathcal{L} = \underbrace{\mathbb{E}_{q_\lambda(\theta)} \left[\sum_i \mathbb{E}_{q_\phi(z_i|x_i)} [\log p(x_i|z_i, \theta)] \right]}_{\text{reconstruction}} - \underbrace{\sum_i \text{KL}(q_\phi(z_i|x_i)||p(z_i))}_{\text{latent KL}} - \underbrace{\text{KL}(q_\lambda(\theta)||p(\theta))}_{\text{weight KL (new)}}.$$

新增 weight KL 项正则化 decoder 权重趋向 prior, 实现 Bayesian weight regularisation.

4(d) Mini-batch gradient [3 marks]

Data-dependent 项按 N/M 放大, weight KL 不放大:

$$\nabla \hat{\mathcal{L}}_M = \nabla \left\{ \frac{N}{M} \sum_{j=1}^M \left[\mathbb{E}_{q_\lambda(\theta)} \left[\mathbb{E}_{q_\phi(z_j|x_j)} [\log p(x_j|z_j, \theta)] \right] - \text{KL}(q_\phi(z_j|x_j)||p(z_j)) \right] - \text{KL}(q_\lambda(\theta)||p(\theta)) \right\}.$$

用 reparameterisation trick 估计期望: $\theta = h(\lambda, \eta)$, $z_j = g(\phi, x_j, \epsilon_j)$.

4(e) Benefits [3 marks]

(1) 抗 **overfitting**: weight KL 提供原则性 regularisation, 小数据集尤其有价值。(2) **Predictive uncertainty**: 对 θ marginalise, 生成分布反映 decoder 不确定性。(3) **Model selection**: ELBO 作为 marginal likelihood 下界可比较模型。代价: 训练更贵; 数据多时收益有限。

4(f) Inference over encoder? [4 marks]

不需要。(1) Encoder 不属于 generative model — ϕ 不出现在 $p(\theta, z, x)$ 中。(2) ϕ 是 variational parameters (同 λ), 对其再做 Bayesian inference 是无限回归。(3) 生成时完全不用 encoder, 其不确定性不影响生成质量。

4(g) Alternative posterior approximations [3 marks]

(1) **MCMC/SGLD**: 对 θ MCMC 采样 + 对 z amortised VI, 渐近精确。(2) **Deep ensembles**: 训练 K 个 VAE, 用 $\{\theta_k\}$ 近似 posterior, 简单易用。(3) **Laplace approximation**: MAP training 后用 Hessian 构造 Gaussian 近似, post-hoc, 无需重训。各有优缺点, 选择取决于精度 vs 计算预算。

5 Question 5: Gradients, Autodiff, Recursion [20 marks total]

5(a)(i) Score function estimator [3 marks]

用 log-derivative trick $\nabla_{\theta} p = p \nabla_{\theta} \log p$:

$$\nabla_{\theta} \mathbb{E}_{p(x|\theta)}[f(x, \theta)] = \mathbb{E}_{p(x|\theta)}[f(x, \theta) \nabla_{\theta} \log p(x|\theta) + \nabla_{\theta} f(x, \theta)].$$

K -sample estimator:

$$\hat{\nabla} = \frac{1}{K} \sum_{k=1}^K [f(x^{(k)}, \theta) \nabla_{\theta} \log p(x^{(k)}|\theta) + \nabla_{\theta} f(x^{(k)}, \theta)], \quad x^{(k)} \sim p(x|\theta).$$

5(a)(ii) Additional reparameterisation assumptions [2 marks]

(1) $f(x, \theta)$ 对 x 可微 (chain rule 需要 $\partial f / \partial x$)。 (2) $g(\theta, \epsilon)$ 对 θ 可微。排除 discrete distributions 和不可微采样。

5(a)(iii) Reparameterised estimator [3 marks]

$x = g(\theta, \epsilon)$, $\epsilon \sim p(\epsilon)$:

$$\hat{\nabla}_{\text{reparam}} = \frac{1}{K} \sum_{k=1}^K \nabla_{\theta} f(g(\theta, \epsilon^{(k)}), \theta), \quad \epsilon^{(k)} \sim p(\epsilon).$$

例: $\mathcal{N}(\mu, \sigma^2) \Rightarrow x = \mu + \sigma\epsilon$, $\epsilon \sim \mathcal{N}(0, 1)$ 。

5(a)(iv) When to prefer which? [2 marks]

Reparameterised (当适用时): 方差显著更低 (pathwise derivative), VAE 训练的标准选择。
Score function: 当 f 对 x 不可微或 p 是 discrete distribution 时 (如 RL 中 discrete actions 的 policy gradient)。更 general 但方差更高。

5(b)(i) Reverse mode autodiff? [2 marks]

不能。(1) Stochastic branching: if $z > x$ 的条件依赖随机 z , computation graph 结构每次不同。(2) Sampling 不可微: $z \sim \text{Uniform}(0, 1)$ 不是 x 的函数, 梯度无法通过采样操作传播。Reverse mode autodiff 无法计算 df/dx 。

5(b)(ii) Symbolic differentiation? [2 marks]

不能。(1) 随机递归, 无封闭形式: 递归深度取决于随机 z , 无法写成固定符号表达式。(2) Stochastic control flow 无法被 symbolic differentiation 处理。 $f(x)$ 是 stochastic program, 执行路径运行时才确定。

5(c) Finding x s.t. $f(x) \approx 4$ [6 marks]

传统 gradient-based 方法和 autodiff/symbolic diff 均不可用。需要无梯度方法。

方法一: **Finite differences + stochastic optimisation**

定义 $L(x) = \mathbb{E}[(f(x) - 4)^2]$ 。

Step 1: Monte Carlo 估计 $\hat{L}(x) = \frac{1}{S} \sum_{s=1}^S (f_s(x) - 4)^2$ (运行 $f(x)$ 共 S 次)。

Step 2: Finite differences 近似梯度: $\widehat{\nabla_x L} \approx \frac{\hat{L}(x+\delta) - \hat{L}(x-\delta)}{2\delta}$ 。

Step 3: SGD 更新: $x \leftarrow x - \eta \widehat{\nabla_x L}$ 。

方法二: **Bayesian optimisation**

将 $L(x)$ 视为 noisy black-box, $x \in [0, 1)$ (一维):

1. 在若干 x 处评估 $\hat{L}(x)$;
2. 拟合 GP surrogate model;
3. 用 acquisition function (如 Expected Improvement) 选下一个 x ;
4. 重复至 $L(x) \approx 0$ 。

一维搜索空间使得 Bayesian optimisation 或 grid search + MC evaluation 都可高效求解。

补充分析: 也可推导 $\mathbb{E}[f(x)]$ 的解析形式。 $z \sim \text{Unif}(0, 1)$, 以概率 $1 - x$ 返回 z (当 $z > x$), 以概率 x 递归。设 $m(x) = \mathbb{E}[f(x)]$:

$$m(x) = \mathbb{E}[z|z > x](1 - x) + (\mathbb{E}[z|z \leq x] + m(x)) \cdot x = \frac{1+x}{2}(1-x) + \frac{x}{2} \cdot x + x \cdot m(x),$$

化简得 $m(x)(1-x) = \frac{1}{2}$, 即 $m(x) = \frac{1}{2(1-x)}$ 。令 $m(x) = 4$ 解得 $x = \frac{7}{8} = 0.875$ 。此解析结果可作为数值方法的验证。